

Gaussian Process Optimization in the Bandit Setting: No Regret and Experimental Design

Niranjan Srinivas, Andreas Krause[†], Sham Kakade^{††}, Matthias Seeger^{†††}

[†]: California Institute of Technology

^{††}: University of Pennsylvania

^{†††}: Saarland University

January 9, 2023

目次

- 1 はじめに
- 2 ベイズ最適化
- 3 GP-UCB
- 4 実験
- 5 まとめ

1 はじめに

背景

ブラックボックス関数

ベイズ最適化

本論文の貢献

2 ベイズ最適化

3 GP-UCB

4 実験

5 まとめ


- 多くの実問題は、目的関数に対する最適変数探索問題として定式化できる
 - 耐久性の高いロボットの開発

ブラックボックス関数

- ブラックボックス関数 f

$$y_i = f(x_i) + \varepsilon_i$$

入力： x_i , 出力： y_i , 誤差： ε_i



- 実応用で扱う対象はブラックボックス関数であることが多い
- ブラックボックス関数は、主に以下の2つの性質を持つ
 - 関数の具体的な形状が不明
 - 各入力における関数値を得るには、大きなコストがかかる

- 多くの実問題は，ブラックボックス関数最適化と等価
- できるだけ少ない関数評価回数で最適化を見つけたい
- 有効な手法としてベイズ最適化がある

- 本研究の目的
- 本研究の意義
 -
 -

1 はじめに

2 ベイズ最適化

問題設定

ガウス過程

ベイズ最適化 1

獲得関数

従来の獲得関数

3 GP-UCB

4 実験

5 まとめ

- 候補入力 $\mathcal{X} = \{x_1, \dots, x_n\}$ が与えられている
- 関数 f を評価して出力 $y_i = f(x_i)$ を得るにはコストがかかる
- できるだけ少ないコストで関数 f を最大化するパラメータ x を求めたい

$$x^* = \arg \max_{x \in \mathcal{X}} f(x)$$

- ガウス過程は、確率分布を用いた複雑で非線形な関数を扱うためのモデルである。
- このような複雑で非線形な関数を扱う場合には、一般的な最適化手法では、解決が困難になることがある。

ガウス過程

任意の入力 $\{x_1, \dots, x_n\}$ に対して $\{f(x_1), \dots, f(x_n)\}$ が n 次元正規分布に従うなら, f はガウス過程に従う.

- 関数 f がガウス過程に従うことを $f(x) \sim \mathcal{GP}(\mu(x), k(x, x'))$
- 平均関数: $\mu(x) = \mathbb{E}[f(x)]$
- 共分散関数 (カーネル関数):
 $k(x, x') = \mathbb{E}[(f(x) - \mu(x))(f(x') - \mu(x'))]$

- f にガウス過程事前分布を仮定する
- 訓練データに基づき, f の事後分布を求める
- 事後分布に基づき最も最大値となりそうな点を次に観測する
- 観測した (x_{next}, y_{next}) を訓練データに追加し, 再び事後分布を求める



variance only

$$\boldsymbol{x} = \arg \max_{\boldsymbol{x}} \sigma_T^2(\boldsymbol{x})$$

mean only

$$\boldsymbol{x} = \arg \max_{\boldsymbol{x}} \mu_T(\boldsymbol{x})$$



1 はじめに

2 ベイズ最適化

3 GP-UCB

提案手法

GP-UCB のアルゴリズム

4 実験

5 まとめ

- 探索・活用に特化した

GP-UCB: Gaussian Process Upper Confidence Bound

$$\mathbf{x}_t = \arg \max_{\mathbf{x}} \mu_{t-1}(\mathbf{x}) + \beta_t^{1/2} \sigma_{t-1}(\mathbf{x}).$$

- β_t は，探索の度合いを表す定数
 - β_t が小さい \rightarrow 探索
 - β_t が大きい

- 初期化: 最初に, f の予測分布を設定する. これは f の予測分布を表すカーネルを選択し, そのカーネルに対応するガウス過程を設定することで行われる.
- アクションの選択: 次に, f の予測分布から, 次のような式を用いてアクションを選択する

- $$a_t = \operatorname{argmax}_{a \in D} (\mu_t(a) + \beta_t \sigma_t(a))$$

ここで, $\mu_t(a)$ は, 時刻 t において, a が選択されると予測される f の平均値を表します. $\sigma_t(a)$ は, 時刻 t において, a が選択されると予測される f の不確実性を表します. β_t は, 時刻 t においてのアクションの選択におけるリスク係数を表します

- 報酬の観測: 選択したアクション a_t に対して報酬 r_t を観測する.
- 予測分布の更新: 次に, 最新のアクション a_t を使用して f の予測分布を更新する. これは, ガウス過程のアップデートによって行われる.

1 はじめに

2 ベイズ最適化

3 GP-UCB

4 実験

実験手法

実験対象データ

実験結果

5 まとめ



- 人工的に作成した合成データ
 - 長さスケールパラメータ 0.2 の二乗指数カーネルからランダムな関数をサンプリング
 - サンプリングノイズ分散
- 46 個のセンサーを用いて 5 日間に渡って収集された温度データ (Intel Research Berkeley)
 - 具体的に説明
- カリフォルニア州 I-880 South 高速道路に設置された交通センサーのデータ
 - 具体的に説明



- 1 はじめに
- 2 ベイズ最適化
- 3 GP-UCB
- 4 実験
- 5 **まとめ**
結論

